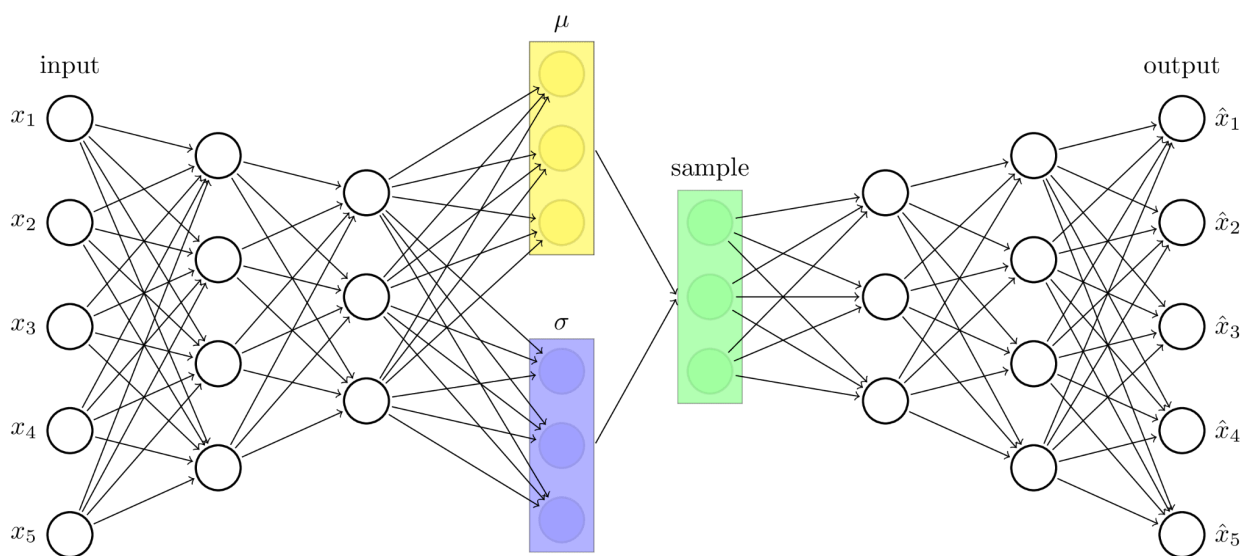


Question 1

- به طور کلی، معماری های Variational AutoEncoder و معماری های associative autoencoders از انواع معماری های autoencoder هستند که برای مطالعه نمایش فشرده ای از دیتا یا encode کردن دیتاست استفاده می شوند.
- معماری VAE ها شامل دو بخش اصلی می شوند:
 - شبکه encoder
 - شبکه decoder
- شبکه encoder دیتای ورودی رو دریافت می کند و اون رو به latent space یا به عبارتی فضایی با بعدی کمتر از ابعاد دیتای ورودی.
- شبکه decoder این دیتای map شده رو به عنوان ورودی دریافت میکند و یک تقریبی از این نقاط رو به ابعاد دیتای اصلی به عنوان خروجی شبکه میدهد.



- در مقابل، معماری های associative autoencoder توانایی تولید دیتای جدید رو ندارند. این معماری ها، توانایی mapping دیتای ورودی به latent space رو دارا نیستند و اغلب

برای تسک هایی مانند Denoising، Dimensionality Reduction، Feature Extraction، Data compression و ... استفاده می شوند.

● همچنین برای تولید دیتای جدید از دیتای ورودی اصلی، با استفاده از معماری های VAE، به صورت زیر عمل می کنیم:

- ابتدا VAE رو با استفاده از دیتای اصلی train می کنیم.
- بعد از یک بار train شدن، از شبکه encoder می توانیم جهت map کردن دیتا به latent space استفاده کنیم.
- سپس برای تولید دیتای جدید، می توان یک نمونه از فضای latent رو از شبکه decoder عبور دهیم تا دیتای جدید تقریبی ساخته شود.

Question 2:

1. واگرایی Kullback-Leibler معیاری برای اندازه گیری اختلاف بین دو توزیع

احتمالاتی می باشد. در VAE ها، بخش واگرایی KL در تابع هزینه، تفاوت بین نمایش latent دیتا ($q_{\phi}(z|x(i))$) و توزیع احتمال $P_{\theta}(z)$ در فضای پنهان را اندازه گیری می کند.

بخش KL-divergence در فرمول تابع هزینه معماری VAE، کمک می کند که نمایش فشرده و معنادار از دیتای ورودی را یاد بگیرد. با به حداقل رساندن KL-divergence، معماری VAE می تواند نمایش پنهان دیتا را ترغیب به یکسان شدن با توزیع قبلی کند که این توزیع معمولاً یک توزیع ساده مانند توزیع نرمال استاندارد انتخاب می شود. در حقیقت، این عملیات مانع از حفظ یا memorizing دیتا توسط معماری VAE می شود.

در مجموع می توان گفت که عاملی که در تابع هزینه معماری های VAE باعث یادگیری نمایش فشرده و معنادار دیتای ورودی می شود، بخش مربوط به KL-divergence می باشد که برای تسک هایی مثل تولید و یا بازسازی دیتا استفاده می شود.

2. مدل سازی $P_{\theta}(z)$ و $q_{\phi}(z|x(i))$ به عنوان توزیع های نرمال با ماتریس کوواریانس مورب، چندین مزیت دارد:

یکی این که از آن جا که توزیع های ساده ای هستند، کار کردن با آنها چه به صورت عملی و چه به صورت تئوری آسان می باشد. توزیع نرمال یک فرم بسته ای از تابع احتمال چگالی هست که این باعث ساده شدن محاسبه احتمالات و انجام محاسبات آماری مختلف می شود. علاوه بر آن، تخمین ماتریس کوواریانس آسان بوده و تفسیر ساده ای هم دارد چرا که هر عنصر آن نشان دهنده واریانس یک بعد واحد می باشد.

یکی دیگر از مزیت ها این است که مدل سازی فضای پنهان با یک توزیع نرمال به همراه ماتریس کوواریانس قطری امکان نمونه گیری کارآمد رو فراهم میکند. نمونه گیری از یک توزیع نرمال از نظر میزان محاسبات بسیار کارآمد می باشد و ماتریس کوواریانس قطری هم امکان نمونه برداری از هر بعد را به صورت مستقل فراهم می کند که این امر هم می تواند از پیچیدگی محاسبات بکاهد.

در نهایت مدل سازی فضای پنهان با استفاده از توزیع نرمال و یک ماتریس کوواریانس قطری می تواند انتخاب بسیار مفیدی برای انجام بسیاری از کاربرد های معماری های VAE، مانند تولید دیتا، باشد.

3. بخش اول تابع هزینه به $reconstruct\ loss$ معروف است و برای اندازه گیری مقدار دیتای اصلی و دیتای بازسازی شده کاربرد دارد. این بخش به صورت کلی با استفاده از محاسبه مقدار میانگین مربع خطا (MSE) و یا محاسبه آنتروپی متقاطع باینری (BCE) بین دو مقدار دیتای اصلی و دیتای بازسازی شده به دست می آید.

بخش هزینه بازسازی (The reconstructed loss)، به دلیل کمک به VAE در بازسازی دیتای ورودی با دقت بالا، از اهمیت بالایی برخوردار است. با به حداقل رساندن این بخش از تابع هزینه، معماری VAE قادر است یک نمایش فشرده و معنادار از داده ها را بیاموزد که قادر به بازسازی دقیق داده های ورودی باشد.

بخش هزینه بازسازی تاثیر غیرمستقیم بر فضای پنهان دارد، زیرا VAE یاد می گیرد که داده های ورودی را به یک نمایش نهفته فشرده و معنادار که قادر به بازسازی دقیق

داده‌های ورودی است، نگاشت کند. با به حداقل رساندن این بخش، VAE قادر به یادگیری یک نمایش نهفته است که می‌تواند ویژگی‌های مهم داده‌های ورودی را ضبط کرده و آن را به طور دقیق بازسازی کند.

و در نهایت می‌توان با توجه به موارد بالا گفت که بخش reconstruction loss یک نقش حیاتی در معماری‌های VAE بازی میکند. زیرا با کمکی که به VAE می‌کند، باعث می‌شود که آن، نمایش فشرده و معناداری از داده‌ها را بیاموزد که قادر به بازسازی دقیق داده‌های ورودی باشد.